

# Análisis Lineal Discriminante \_



# Motivación

# Preliminares

- El Análisis Lineal Discriminante (ALD) es otra variante de algoritmo generativo.
- En Bayes Ingenuo evaluamos la ocurrencia de una clase, condicional a la distribución de la verosimilitud.
- En ALD, la ocurrencia de una clase se evalúa en función a distribuciones multivariadas y una frontera de decisión.
- Busca generar una nueva reexpresión de los datos en una dimensión en base a distribuciones multivariadas normales.

# **Distribución Multivariada Normal**


# Distribución Multivariada Normal

$$\text{MultiNormal}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi^{\mathbb{N}/2} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left[ -\frac{1}{2} (x - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (x - \boldsymbol{\mu}) \right]$$

- La distribución multivariada normal permite evaluar el comportamiento de un conjunto de atributos y datos en cuanto a una distribución más compleja.
- A grandes rasgos, es una expansión de la distribución normal ya estudiada, considerando la inclusión de dos o más variables.

# Distribución Multivariada Normal


$$\text{MultiNormal}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi^{\mathbb{N}/2} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left[ -\frac{1}{2} (x - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (x - \boldsymbol{\mu}) \right]$$


$$\begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}$$

Vector de medias para  
cada uno de los atributos

# Distribución Multivariada Normal


$$\text{MultiNormal}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi^{\mathbb{N}/2} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left[ -\frac{1}{2} (x - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (x - \boldsymbol{\mu}) \right]$$


$$\begin{bmatrix} \sigma_{11}^2 & \sigma_{12} & \cdots & \sigma_{1n} \\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{m1}^2 & \sigma_{m2} & \cdots & \sigma_{mn}^2 \end{bmatrix}$$

Matriz de varianza  
(elementos diagonales) y  
covarianza (elementos en  
los triángulos)

# Distribución Multivariada Normal

$$\text{MultiNormal}(\mu, \Sigma) = \frac{1}{2\pi^{\mathbb{N}/2} |\Sigma|^{\frac{1}{2}}} \exp \left[ -\frac{1}{2} (x - \mu)^{\top} \Sigma^{-1} (x - \mu) \right]$$



Evalúa la distancia de un punto específico respecto a media de todos los atributos existentes.




# Distribución Multivariada Normal

$$\text{MultiNormal}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi^{\mathbb{N}/2} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left[ -\frac{1}{2} (x - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (x - \boldsymbol{\mu}) \right]$$

Regula la forma de la  
elipse.

# Distribución Multivariada Normal




# La idea base detrás de LDA

# Preliminares

El análisis lineal discriminante se puede representar en tres pasos:

- Extraer parámetros de los datos.
- Estimar las distribuciones en base a los parámetros.
- Reexpresar la clasificación en función a una nueva proyección de datos.

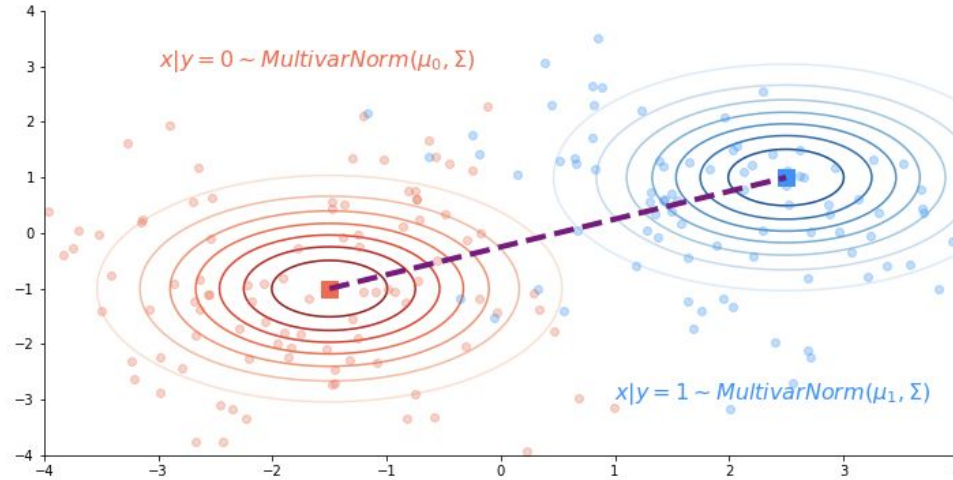
# Extracción de parámetros para cada clase



Buscamos las medias de cada atributo  $\mu \quad \forall x \in \mathbf{X}$  condicional la clase.

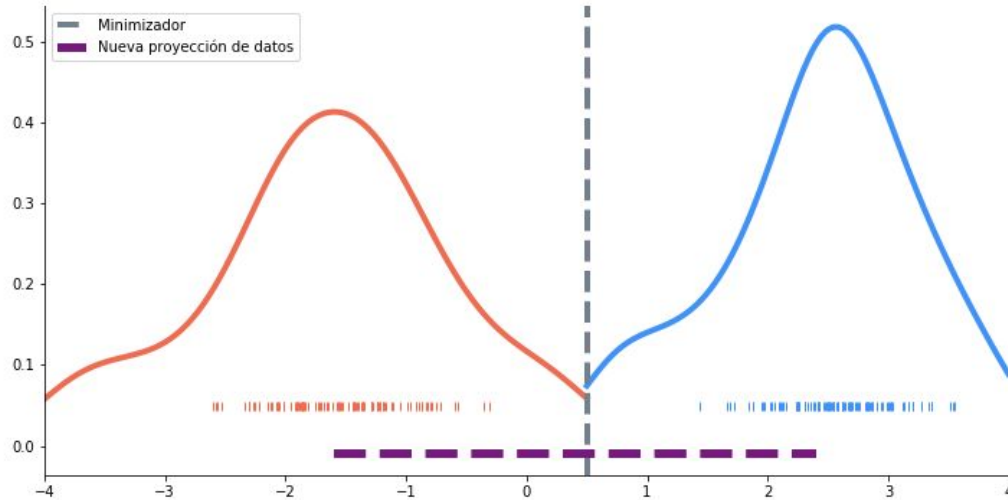
Hasta el momento, asumimos que la matriz de covarianza será idéntica para cada clase.

# Estimar las distribuciones



Estimamos las elipses de cada clase mediante  $x|y \in \mathbb{Y} \sim \text{MultivarNorm}(\mu, \Sigma)$   
En base a las elipses evaluamos la varianza interna y externa.

# Preliminares



Mediante la maximización de la varianza externa, evaluamos un discriminante lineal. Este discriminante buscará reducir la superposición de las observaciones de cada clase.

# Quadratic Discriminant Analysis



# Consideraciones


- **Principal diferencia con ALD clásico:** Los atributos siguen una forma cuadrática.
- **Otra virtud:** la matriz de covarianza es condicional a cada una de las clases.
- De esta manera, ambos elementos apuntan a flexibilizar el comportamiento de las funciones de decisión.

# Apreciaciones

# Análisis Lineal Discriminante vs PCA


## PCA:

component axes that maximize the variance



## LDA:

maximizing the component axes for class-separation



- Ambos métodos buscan generar una nueva proyección entre los datos.
- ALD maximiza la separación de clases.
- PCA maximiza la varianza en los datos, agnóstica a las clases existentes.

# **Análisis Lineal Discriminante y Regresión Logística**

- Ambos métodos generan resultados similares.
- La principal diferencia es cómo se genera el fit en cada uno.
- ALD será asintóticamente eficiente si es que se cumple el supuesto de distribución gaussiana a nivel de clase.

**{desafío}**  
**latam\_**

*Academia de  
talentos digitales*

[www.desafiolatam.com](http://www.desafiolatam.com)